

Inteligencia de Negocios

Business Intelligence

Open Data y Limpieza de Datos con Excel y Power Query

- 1. Datos Abiertos (Open Data) características
- 2. Sector Infomediario. Valor del Open Data
- 3. Limpiar y reestructurar datos importados
- 4. Funciones y Herramientas de Excel que nos pueden ayudar
- 5. Power Query para limpiar y estructurar datos



Open Data son datos que pueden ser utilizados, reutilizados y redistribuidos libremente por cualquier persona, incluso para fines comerciales, para cualquier finalidad y que se encuentran sujetos, cuando más, al requerimiento de atribución y de compartirse de la misma manera en que aparecen

(Open Data Handbook, 2010)

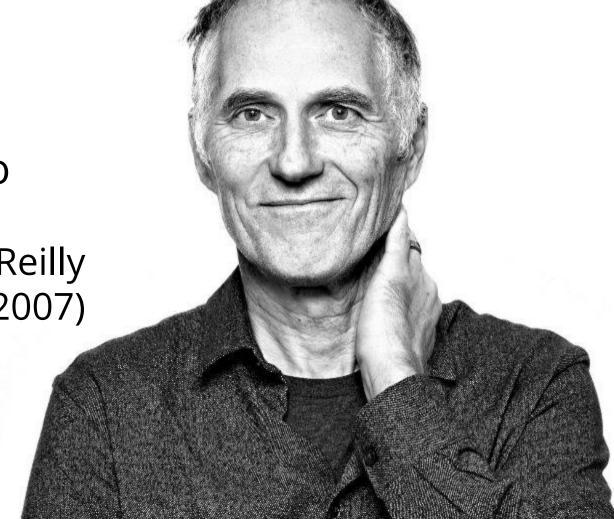


https://okfn.org/



Los datos abiertos en realidad podrían ser más importantes que el código abierto

Tim O'Reilly (2007)



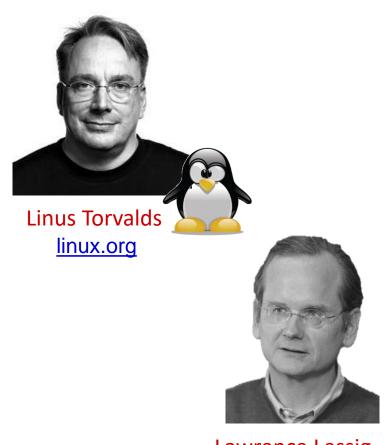


Surge como una de las iniciativas que tienen origen en la filosofía abierta de internet.





surgida en 1983



Lawrence Lessig creativecommons.org



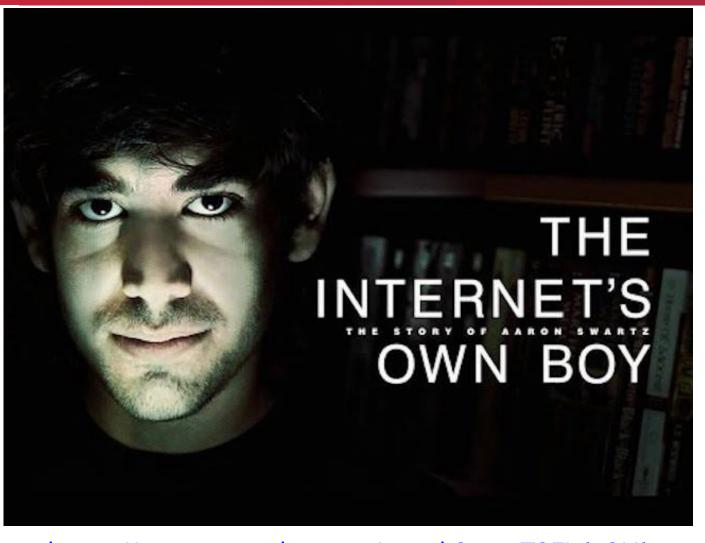
Sir Tim Berners Lee



www.w3c.es w3schools.com







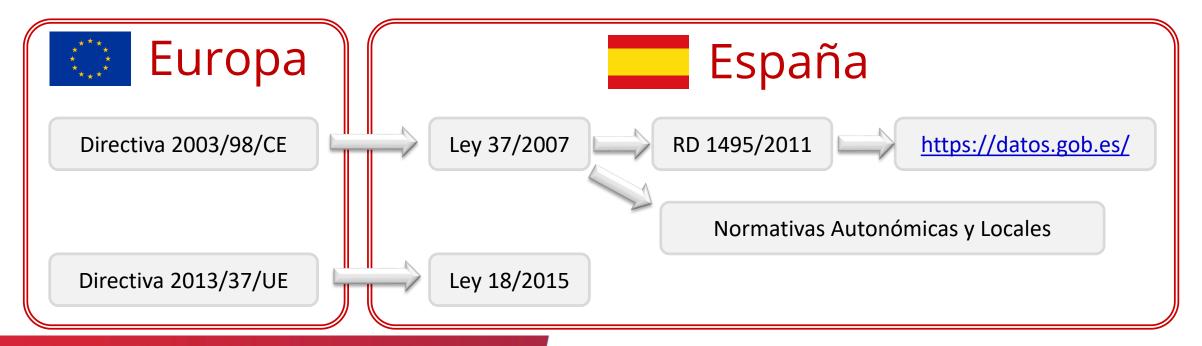
https://www.youtube.com/watch?v=mT8FJcIx3HI



Open Data juega un importante papel en el Open Goverment,

ya que **garantiza** a los ciudadanos el **acceso a la información generada por** los gobiernos y las administraciones públicas en el transcurso de sus actividades.

El marco general para garantizar que las condiciones de reutilización de los documentos del sector público fueran equitativas, proporcionadas y no discriminatorias, se encuentra en la DIRECTIVA 2003/98/CE del Parlamento Europeo y del Consejo.











Públicos: No sujetos a limitaciones de privacidad, seguridad o privilegios



En Bruto: Se deben publicar tal y como se recogen de la fuente, manteniendo el mayor nivel de detalle posible.



Actualizados: En rápida disposición para preservar el valor de los mismos.



Accesibles: Disponibles para el mayor número de usuarios posible y para la más amplia gama de propósitos.



Estructurados:

Que puedan ser procesados de manera automática por cualquier ordenador.



Sin Registro: (acceso anónimo) Disponibles para cualquier persona, sin necesidad de registro.



Abiertos: Disponibles en un formato tal, que ninguna entidad posea su control exclusivo.



Libres: *>

No sujetos a ninguna norma de derechos de autor, patentes o copyright



En cualquier caso, el coste de acceder a los datos abiertos debe ser razonable y corresponderse con el coste de ofrecer los datos con los requisitos solicitados.



Sistema de 5 estrellas de Tim Berners-Lee https://5stardata.info/es/

*	**	***	***	****
Datos no estructurados	Datos estructurados	Datos estructurados Formato no propietario	Datos estructurados Formato no propietario URL única y estática	Datos estructurados Formato no propietario URL única y estática Bases de Datos interconectadas
PDF	EXCEL	CSV	R D F	

Es importante destacar que aunque los datos estén en un determinado formato, esto no quiere decir que los mismos se encuentren estructurados de la forma que necesitamos





Los datos están disponibles en la web, sea en el formato que sea, con licencia abierta.

Sin embargo, los datos están atrapados en un documento.

Para su utilización, deben transcribirse o utilizar software para extraerlos.

Para realizar un análisis sobre los mismos, se requiere reestructurarlos.

Tabla 1: Características de la población. Muestras Seguridad Social y funcionarios públicos. ENS 2003-2012

públicos. ENS 2003-2012							
Todas las bases ENS 2003, 2006 y 2012							
VARIABLES	Todos=72.135	SS=68.390	Sólo mutualidad pública=3.745				
SEXO							
Mujeres	56.8%	56.9%	52.0%				
Varones	43.2%	43.1%	48.0%				
GRUPOS DE EDAD							
16-24	8.2%	8.2%	8.3%				
25-54	50.2%	49.9%	55.7%				
55-64	14.1%	14.0%	16.5%				
65 o más	27.5%	28.0%	19.6%				
ESTADO CIVIL							
Soltero	26.7%	26.7%	26.7%				
Casado	55.3%	55.0%	59.2%				
Viudo	12.8%	13.0%	8.6%				
ESTUDIOS							
ESO o menos	61.5%	63.3%	28.6%				
Secundaria segunda etapa	18.0%	17.9%	21.3%				
Superior	20.5%	18.9%	50.0%				
ESTADO DE SALUD							
Muy bueno	13.7%	13.4%	19.7%				
Bueno	50.9%	50.6%	56.7%				
Regular	25.4%	25.9%	18.0%				
Malo	7.7%	7.9%	4.6%				
Muy malo	2.2%	2.3%	1.0%				
PESO							
Insuficiente	5.1%	5.1%	5.6%				
Normal	53.2%	53.0%	56.4%				
Sobrepeso	34.3%	34.4%	32.5%				
Obesidad	7.0%	7.1%	5.3%				
SITUACION LABORAL							
Jubilado (65 o más)	31.9%	32.4%	24.0%				
Activo	49.7%	49.1%	59.8%				
Inactivo	18.4%	18.5%	16.3%				
COMUNIDAD AUTÓNOMA							
Andalucía	9.7%	9.7%	9.1%				
Aragón	7.0%	6.9%	7.1%				
Asturias	3.5%	3.5%	3.7%				
Islas Baleares	4.3%	4.4%	3.2%				
Canarias	4.2%	4.2%	3.7%				
Cantabria	4.3%	4.4%	2.9%				
Castilla La Mancha	9.6%	9.4%	12.8%				
Castilla y León	4.2%	4.2%	3.8%				
Cataluña	9.1%	9.2%	7.3%				
Com. Valenciana	6.6%	6.7%	4.9%				
Extremadura	3.5%	3.5%	3.4%				
Galicia	7.9%	8.0%	7.3%				
Com. de Madrid	7.7%	7.5%	10.2%				
Murcia	4.9%	4.9%	5.2%				
Navarra	4.3%	4.4%	2.7%				
Pais Vasco	4.6%	4.6%	4.7%				
La Rioja	2.8%	2.8%	2.1%				
Ceuta	1.6%	1.4%	5.1%				
Melilla	0.4%	0.3%	0.9%				

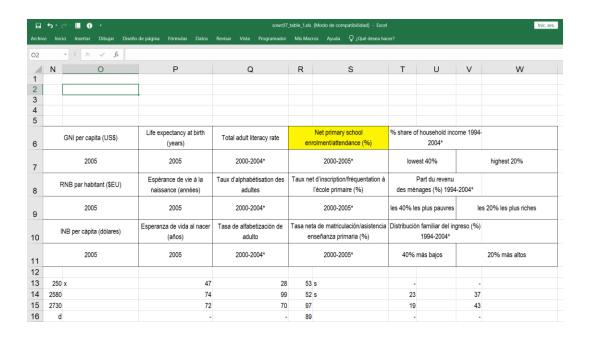




Los datos están disponibles en la web, en forma 'estructurada' (es decir, en formato para máquinas) y con licencia abierta.

Sin embargo, para extraerlos se necesita un software propietario.

Es posible, que para realizar un análisis sobre los mismos, se requiera reestructurarlos.



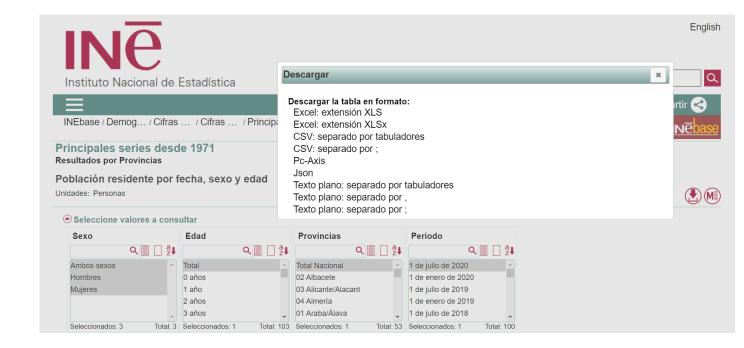




Los datos están disponibles en la web, en forma estructurada (es decir, en formato para máquinas) y con licencia abierta.

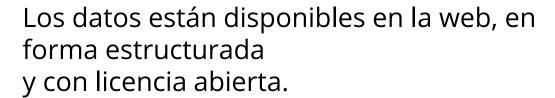
Sin embargo, todavía son solo datos publicados en la Web y no datos integrados a la Web.

Es posible, que para realizar un análisis sobre los mismos, se requiera reestructurarlos.











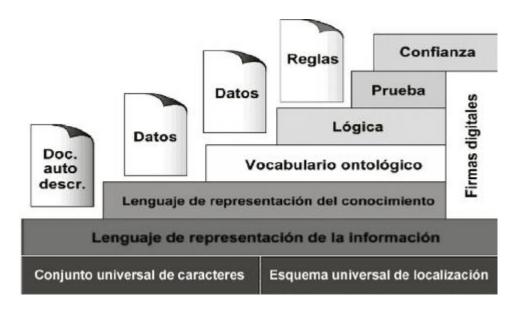
Se puede enlazar los datos desde otro sitio web, marcarlos como favoritos, reutilizar partes de los mismos, usar herramientas y librerías existentes o incluso combinarlos con otros datos.



Una forma de representar los datos es utilizar RDF, sin embargo otros formatos como Atom pueden ser convertidos/mapeados, si se requiere.



















Las cinco estrellas se consiguen logrando los niveles anteriores y además, enlazándolos con otros datos.

Tanto el consumidor de los datos, como el editor de los mismos se benefician del efecto red.

Vincular los datos con los datos de otras organizaciones, proporciona contexto.



https://opendatabarometer.org/country-detail/? year=2016&indicator=ODB&detail=ESP https://data.europa.eu/sites/default/files/open data maturity report 2019.pdf



El sector infomediario representa al conjunto de empresas que generan productos y servicios a partir del Open Data.

Incluye a las empresas que se han creado específicamente para este fin, como a aquellas que incorporan de alguna manera los datos abiertos.

0

Grado reusabilidad

Datos abiertos

Datasets

Valor de reuso

> Desarrollo de productos y servicios

Desarrollo de Apps

3

Valor económico y social

Distribución y comercialización de productos y

Valor social y de mercado

⇒ https://eixos.cat/



	2016
Empresas Identificadas	636
Volumen de Negocio	1.704.829.680 €
Empleados	19.362
Capital Suscrito	366.023.315 €

El valor de los Datos en el Ecosistema Global

Encuentro Aporta. 7ª Edición. 2017

https://datos.gob.es/sites/default/files/aportameeting/evento_aporta-asedie_dionisio_torre_v2_1.pdf

Del sector infomediario a la economía del dato

Observatorio Nacional de Tecnología y Sociedad (ONTSI)

https://www.ontsi.red.es/sites/ontsi/files/2020-06/EstudioInfomediarioEdicion2020.pdf

Indicadores ONTSI

https://www.ontsi.red.es/es/indicadores

Oferta del Sector

56,8%

DATOS TRATADOS

55,6%

PUBLICACIONES

45,7%

MAPAS Y VISUALIZACIONES



¿Cómo limpiar y reestructurar los datos?

Es **casi seguro**, que para realizar un análisis con datos importados, se requiera reestructurarlos.



La recogida,

limpieza

y transformación de datos

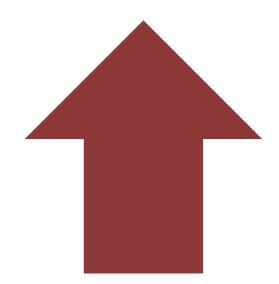
constituye un 80%

del trabajo de análisis



https://blog.sedic.es/2019/03/18/los-cientificos-de-datos-pasan-el-80-del-tiempo-limpiando-datos-y-el-otro-20-protestando-por-tener-que-limpiarlos/





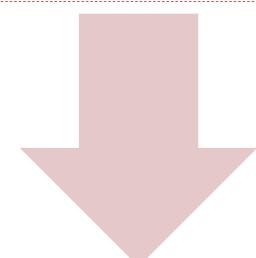
Análisis recurrentes sobre los mismos datos



Data Cleaning Software
ETL Software
Macros

Power Query

Automatización de la limpieza de los datos



Análisis circunstancial sobre un tópico



Limpieza manual, ayudado de un software







Los errores en el tratamiento de datos son tan comunes que existe una organización llamada Grupo Europeo de Evaluación de Riesgos para Hojas de Cálculo (ESRIG) que hace recomendaciones al respecto.



http://www.eusprig.org/

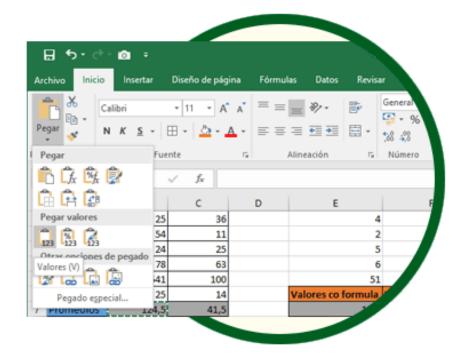


Funciones y Herramientas de Excel que nos pueden ayudar





Tomar en cuenta que una vez realizado los cambios con estas funciones, habrá que copiar y pegar valores en la columna que contiene la fórmula y eliminar la columna que está "sucia".



El operador & y la Función CONCATENAR



El símbolo u operador & permite unir o concatenar una o más cadenas de texto con el fin de generar un único fragmento de texto.

La función CONCATENAR realiza la misma acción.

=CONCATENAR (referencia1/texto1; referencia2/texto2; ...)

	А	В	С
1	Nombre	Apellido	Trato
2	Rita	de la Torre	Prof.
3	Paco	Pérez	Señor
4			

Prof. Rita de la Torre	=CONCATENAR(C2;" ";A2;" ";B2)	=C2 & " " & A2 & " " & B2
Señor Paco Pérez	=CONCATENAR(C3;" ";A3;" ";B3)	

En informática en general, los textos literales se escriben entre comillas. En el ejemplo, el espacio entre comillas permite separar trato, nombre y apellidos.



Asistente de texto en columnas

Excel permite tomar el texto de una o más celdas y propagarlo en varias de ellas.

Para ello usaremos la herramienta Texto en Columnas en la ficha Datos de la Cinta.



- Selecciona la celda o columna que contenga el texto a dividir en columnas.

 Asimismo, verifica que existen suficientes columnas vacías a la derecha de la celda o columna seleccionada
- Haz clic sobre el botón Texto en columnas en la ficha Datos.
 - Pantalla 1 Indica si los datos están Delimitados o tienen un ancho fijo
 - Pantalla ② Indica el carácter empleado como separador de campos si has seleccionado Delimitados en la pantalla 1, o establece el ancho de los campos (saltos de columna).

Pantalla Selecciona las columnas que desees importar y establece el tipo de datos y/o formato de ser necesario. Adicionalmente, si pulsas el botón Avanzadas... podrás indicar cuál es el separador decimal y el separador de miles utilizados en los datos que estás importando.



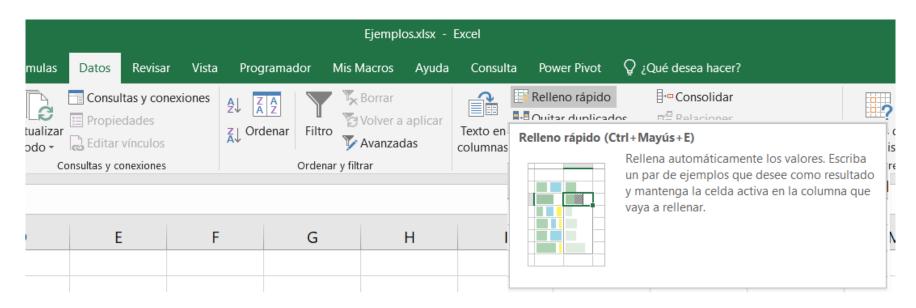
Funciones para extraer partes de una fecha (o calcular fechas posteriores)

	А	В	С	D	E
3	Fecha:	22/04/2021			
4			•		
5	Función	Se usa para	Sintaxis	Ejemplo	Resultado
6	DIA	Extraer el dia de una fecha	=DIA(ref)	=DIA(B3)	22
7	MES	Extraer el mes de una fecha	=MES(ref)	=MES(B3)	4
8	AÑO	Extraer el año de una fecha	=AÑO(ref)	=AÑO(B3)	2021
9	DIASEM	Extraer el dia de la semana de una fecha	=DIASEM(ref)	=DIASEM(B3)	5
10	NUM.DE.SEMANA	Extraer el número de la semana de una fecha	=NUM.DE.SEMANA(ref;[tipo])	=NUM.DE.SEMANA(B3)	17
	FIN.MES	Indicar el último día del mes de una fecha, sin el argumento meses	=FIN.MES(ref;[meses])	=FIN.MES(B3)	30/04/2021
11		o de la fecha restando o sumando meses a la misma			
12	FECHA.MES	Suma o Resta meses a una fecha dada.	=FECHA.MES(ref; meses)	=FECHA.MES(B3;1)	22/05/2021

Funciones para extraer partes de un texto

	А	В	C	D	E
3	Texto	Barcelona-Ciutat-Condal			
4					
5	Función	Se usa para	Sintaxis	Ejemplo	Resultado
6	IZQUIERDA	Extraer x caracteres a la izquierda de un texto	=IZQUIERDA(ref;caracteres)	=IZQUIERDA(B3;9)	Barcelona
7	EXTRAE	Extraer x caracteres a partir de una posición en un texto	=EXTRAE(ref;posición;caracteres)	=EXTRAE(B3;11;6)	Ciutat
8	DERECHA	Extraer x caracteres a la derecha de un texto	=DERECHA(ref; caracteres)	=DERECHA(B3;6)	Condal
9	LIMPIAR	Quita todos los caracteres no imprimibles del texto	=LIMPIAR(ref)	=LIMPIAR(B3)	Barcelona Ciutat Condal





versión Excel 2013 y posteriores.

El botón Relleno rápido rellena una columna con datos, automáticamente, cuando detecta un patrón.

Esto permite, por ejemplo, usarlo para separar los nombres y apellidos en una sola columna, o viceversa, combinar datos de dos columnas diferentes.



Convertir números almacenados como textos a números

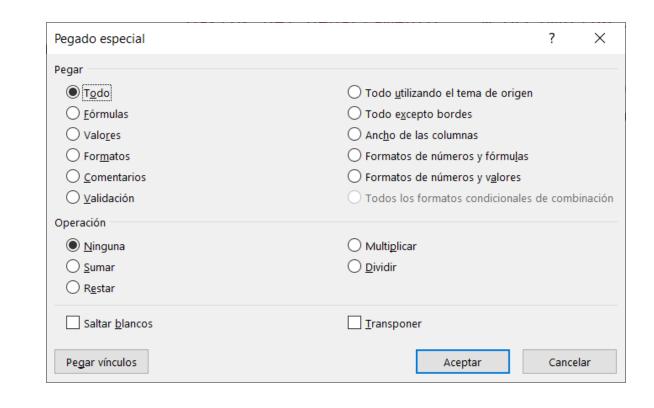
123

123

'123

- 1. Escribir el número 1 en una celda en blanco.
- 2. Clic sobre el icono Copiar
- 3. Seleccionar los números almacenados como textos
- 4. Clic con el botón derecho y seleccionar Pegado especial.
- 5. Del cuadro de diálogo que aparece, seleccionar Multiplicar

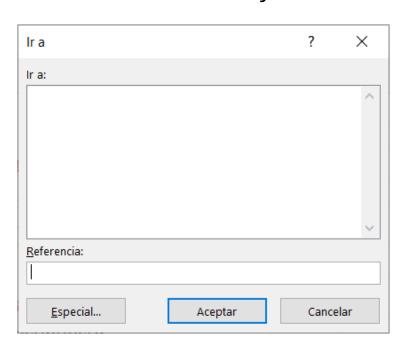
Los números se pegarán como tales.



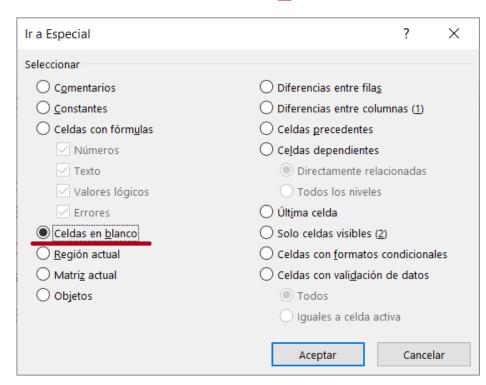


Seleccionar y rellenar todas las celdas en blanco

1. Presionar la tecla **F5**, y del cuadro de diálogo **Ir** a... seleccionar **Especial**.



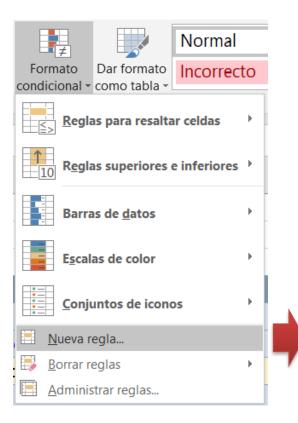
2. Seleccionar Celdas en <u>b</u>lanco.



3. Escribir el texto o fórmula deseados y presionar simultáneamente las teclas Ctrl Enter.



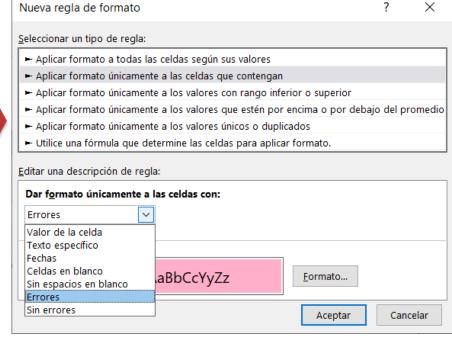
Resaltar y corregir errores



Función SI.ERROR

Sintaxis:

=SI.ERROR(valor; valor_si_error)





Función TEXTO para formatear números complejos

(Ver documento *Formatos personalizados en Excel* para para mayor detalle)

Permite cambiar la apariencia de un número aplicándole formato con códigos de formato.

Es útil cuando se desea concatenar números con texto o símbolos en una misma celda.

Si el formato deseado es de tipo decimal o moneda, se pueden utilizar las funciones **DECIMAL** o **MONEDA** respectivamente. Esta última tomará la configuración de Windows.

Ejemplos:

	Α	В	C	D
1				
2	Año:	2020		
3				="Gastos de la empresa para el año " &B2 & ": " & MONEDA(B4)
4	Gastos de la Empresa:	120.000,00€		Gastos de la empresa para el año 2020: 120.000,00 €
5				="Gastos del departamento: " & DECIMAL(B6;2) & " euros"
6	Gastos del Departamento:	35.000,00 €		Gastos del departamento: 35.000,00 euros ←
7				="El departamento ha consumido un " & TEXTO(B8;"00,00%") & " del presupuesto"
8	Porcentaje:	29,17%		El departamento ha consumido un 29,17% del presupuesto
9				

Eliminar espacios extras

```
welcome to digital vidya
welcome to digital vidya
welcome to digital vidya
welcome to digital vidya
```

Función:

=ESPACIOS(referencia)

Cambiar texto a

```
MAYÚSCULAS,
minúsculas,
Nombre Propio
```

Funciones:

```
=MAYUSC (referencia)
```

=MINUSC(referencia)

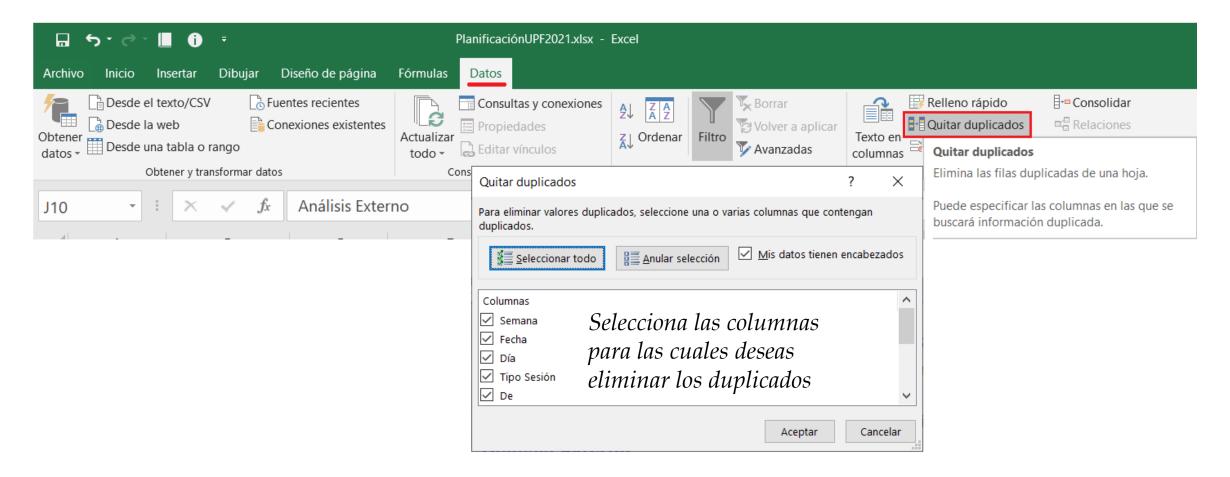
=NOMPROPIO(referencia)

Respectivamente.

Tomar en cuenta que una vez realizado los cambios con estas funciones, habrá que copiar y pegar valores en la columna que contiene la fórmula y eliminar la columna que está "sucia".



Eliminar Duplicados



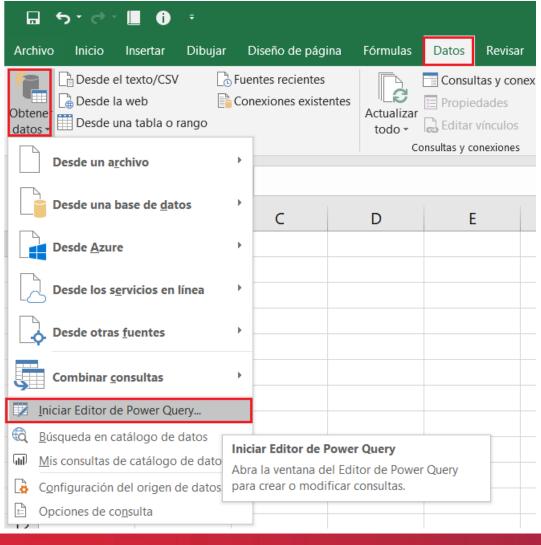




Limpiar los Datos con Power Query



https://www.howtoexcel.org/power-query/the-complete-guide-to-power-query/



Power Query

es un motor de transformación y preparación de datos que viene en forma de complemento para Microsoft Excel y Power BI.

Power Query permite extraer información de distintas fuentes de datos, limpiarlos y transformarlos según necesites, para posteriormente cargarlos en algún sitio para su posterior uso; ya sea en una tabla de Excel o en un modelo de datos.

En Excel, podemos encontrarlo en la pestaña Datos de la cinta, en el primer icono (Obtener Datos) de la sección Obtener y transformar datos: Iniciar Editor de Power Query tal y como se muestra en la imagen.



- Herramienta ETL
- Lenguaje M
- Obtener Datos
- Transformar Datos
- Combinar Tablas
- Fusionar Tablas
- Enriquecer Datos

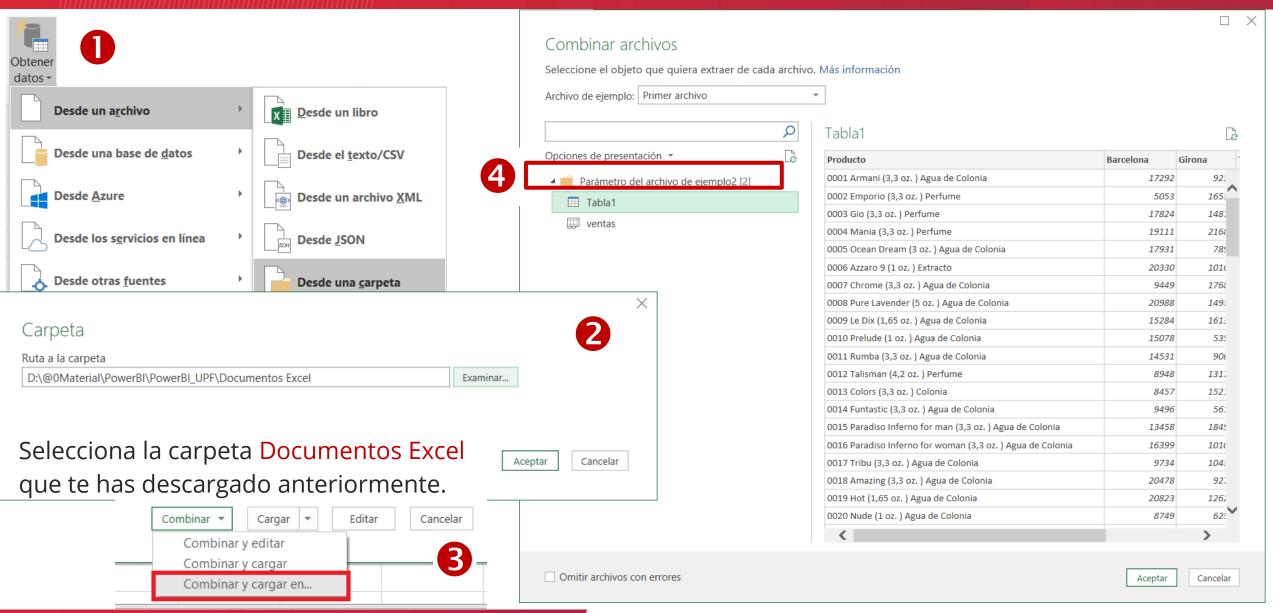
Transformación de Datos con Power Query				
OPERACIONES CON COLUMNAS	GENERACIÓN DE COLUMNAS	LENGUAJE M		
Filtrado	Duplicación			
Ordenación	Cálculos Básicos			
Cambiar valores	Cálculos Avanzados			
Pivotar				
Despivotar				
Dividir				
Combinar				
Expandir				
		Power Query		



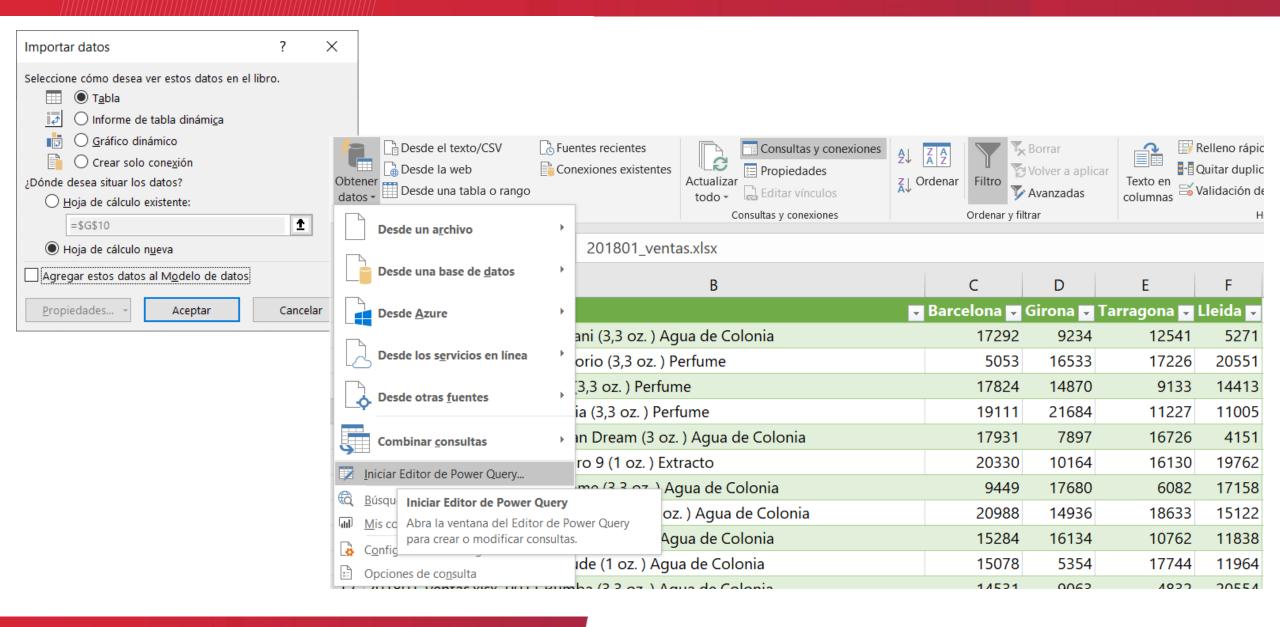
- Descarga la carpeta Documentos Excel,
 que se encuentra dentro de la carpeta Open Data.
- En la subcarpeta Documentos Excel hallarás seis archivos 201801_ventas.xlsx... 201806_ventas.xlsx.
 Todos estos archivos guardan las ventas hipotéticas del mes de una empresa y presentan la misma estructura de datos.
- Combinaremos todos los archivos de Excel haciendo uso del Power Query.















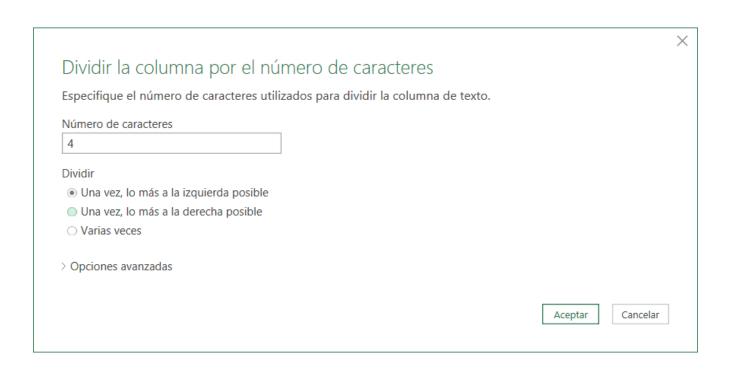


- Selecciona la primera columna Source. Name y haz clic sobre la misma con el botón derecho.
- Selecciona ahora la opción Reemplazar los Valores.
- Indica que quieres reemplazar el valor _ventas.xlsx por un valor vacío, como se muestra en pantalla.
- Al presionar Aceptar,
 fíjate cómo a la derecha
 de la pantalla, en la lista
 Configuración de la Consulta Pasos Aplicados,
 Power Query va apuntando
 las transformaciones
 realizadas.

Reemplazar los valores	
Reemplace un valor con otro de las columnas seleccionadas.	
Valor que buscar	
_ventas.xlsx	
Reemplazar con	
Onsignes avangadas	
> Opciones avanzadas	
	The state of the s
	Aceptar Cancela



- Ahora dividiremos la columna resultante en año y mes.
 Para ello selecciona del menú emergente (clic derecho en la columna)
 la opción Dividir columna -> Por número de caracteres
- Indica 4 en el número de caracteres y haz clic sobre OK



- Cambia el nombre a las dos primeras columnas por Año y Mes respectivamente haciendo doble clic sobre el encabezado de las mismas.
- Repite el proceso con la columna Producto. Indica Id y Producto como nombre de las columnas resultantes



- Ahora selecciona las cuatro primeras columnas de la tabla, haz clic con el botón derecho y selecciona la opción Anulación de dinamización de otras columnas.
- Cambia el nombre de las columnas Atributo por Provincia y Valor por ventas.
- Cierra y aplica los cambios



(botón Cerrar y Cargar)

■	1 ² ₃ Año ▼	1 ² ₃ Mes ▼	1 ² ₃ Id ▼	A ^B _C Producto ▼	A ^B _C Provincia ▼	1.2 Ventas
1	2018	1	1	Armani (3,3 oz.) Agua de Colonia	Barcelona	17292
2	2018	1	1	Armani (3,3 oz.) Agua de Colonia	Girona	9234
3	2018	1	1	Armani (3,3 oz.) Agua de Colonia	Tarragona	12541
4	2018	1	1	Armani (3,3 oz.) Agua de Colonia	Lleida	5271
5	2018	1	2	Emporio (3,3 oz.) Perfume	Barcelona	5053
6	2018	1	2	Emporio (3,3 oz.) Perfume	Girona	16533
7	2018	1	2	Emporio (3,3 oz.) Perfume	Tarragona	17226
8	2018	1	2	Emporio (3,3 oz.) Perfume	Lleida	20551
9	2018	1	3	Gio (3,3 oz.) Perfume	Barcelona	17824
10	2018	1	3	Gio (3,3 oz.) Perfume	Girona	14870
11	2018	1	3	Gio (3,3 oz.) Perfume	Tarragona	9133
12	2018	1	3	Gio (3,3 oz.) Perfume	Lleida	14413



- √ http://trucosycursos.es/todo-los-metodos-para-extraer-caracteres-de-una-celda-excel/
- ✓ https://www.exceltip.com/es/como-dividir-numeros-y-texto-de-cadena-en-excel.html
- √ https://opengovdata.org/
- √ https://ciberimaginario.es/2018/07/25/sobre-datos-abiertos/
- √ https://datos.gob.es/es/catalogo
- √ https://data.europa.eu/es
- ✓ https://www.ospi.es/export/sites/ospi/documents/documentos/cotec_informe_reutilizacion-de-datos.pdf



We make it happen